Scaling Dexterous Manipulation via Action Representation Pretraining

Yanjinghao Xu Jiexin Zhang Huan Zhao Jianjia Mo
Zhenghao Yin Dingkang Liang Xiang Bai Han ding
Huazhong University of Science and Technology

Abstract

大规模视觉、语言与视频预训练显著提升了机器人操作模型的感知与泛化能力，但复杂灵巧操作的动作生成仍受到机器人示范稀缺的制约。有限的机器人示范需要同时用于学习动作表征与任务条件下的动作分布，使动作表征难以得到充分训练，进而限制下游生成模型生成复杂灵巧动作的能力。为此，我们提出 ARPG（Action Representation Pretraining and Generation）方法，将动作表征学习与动作生成显示分离：首先使用大规模人类操纵数据预训练一个动作表征编码器。然后，冻结编码器并训练一个紧凑的生成主干（130M 参数量），以学习在编码器表示空间中任务条件下的动作分布。实验结果表明，ARPG 在 DexJoCo 基准上取得了最先进的性能，并将双手灵巧操作的平均成功率从 $\pi_{0.5}$ 的 10.1% 提升至 44.7%。规模化实验进一步表明，更广泛的人类操作行为覆盖能够有效提升下游性能。这些结果表明，动作表征预训练为提升复杂灵巧操作能力提供了一个独立的扩展维度。

1 引言

构建能够完成复杂灵巧操作的通用机器人，特别是使用灵巧手完成协调精细的操作，是机器人学习的重要目标。近年来，大规模视觉、语言与视频预训练赋予了机器人策略强大的视觉表征、语义理解与任务泛化能力 (Bi et al., 2026; Ye et al., 2026; Black et al., 2025a; Zheng et al., 2026b)。然而，机器人最终仍需将这些能力转化为具体的操作动作，可靠的动作生成仍然具有显著挑战。主流策略利用机器人示范端到端学习动作生成，模型同时承担从示范中学习适合动作生成的表征与学习特定条件下的动作分布这两项任务，使进一步提升复杂动作生成能力同时受到机器人示范规模与下游模型容量的制约。这一观察引出一个问题：能否通过规模化动作表征预训练持续提升复杂灵巧操作能力，而不依赖同步扩大机器人示范规模和生成主干容量呢?

近期生成模型研究表明，生成模型无需完全从头学习其建模空间：预训练表征既可以用于引导生成模型的内部表征学习，也可以通过预训练编码器直接定义生成空间，从而将表征学习与后续分布建模解耦 (Yu et al., 2025; Zheng et al., 2026a)。然而，将这一思路扩展到机器人动作并不直接，适用于复杂动作生成的表征空间需要既保留足够的动作信息以支持可靠动作恢复，又编码操作过程中的运动与交互语义。预训练视觉编码器已经从大规模视频数据中学习到了丰富的运动与交互语义 (Assran et al., 2025; Mur-Labadia et al., 2026)，但其表征空间本身并非为动作表示与恢复而设计；而若仅依赖动作自监督学习，动作编码器不仅需要从头学习表征，无法复用大规模视觉预训练获得的表征结构，也无法利用视觉模态中蕴含的场景上下文与交互语义。

基于上述思路，我们提出 ARPG（Action Representation Pretraining and Generation），将动作表征预训练与下游任务条件动作生成解耦，并在预训练动作表征空间中进行生成。具体而言，我们采用视觉–动作双塔架构的编码器：冻结的 V-JEPA 2.1 (Mur-Labadia et al., 2026) 提取视觉表征，动作 Transformer 编码动作轨迹，并通过基于 sigmoid loss 的视觉–动作对齐目标 (Zhai et al., 2023) 将动作表征与视觉表征对齐，从而利用大规模视频预训练获得的表征先验。由于动作表征学习与生成学习解耦，动作表征不再需要通过生成目标适配特定机器人本体的动作细节，而可以从数据中学习可复用的动作表征，因此其预训练可以扩展到规模更大的第一视角人类操作数据 (Hoque et al., 2026; Punamiya et al., 2026)。预训练后，我们冻结动作塔，并将其作为动作表征编码器，利用机器人示范训练动作解码器，将动作表征恢复为可执行的连续动作。在此基础上，下游策略只需在固定的动作表征空间中学习任务条件动作分布：真实的未来动作块 (Zhao et al., 2023) 经冻结的动作编码器映射为生成目标，DiT 生成主干 (Peebles & Xie, 2023) 则根据任务条件，通过 Flow Matching (Lipman et al., 2023) 生成未来动作表征，并由动作解码器恢复为可执行动作。

我们在 DexJoCo 仿真基准 (Wang et al., 2026) 和真实机器人平台上评估 ARPG。尽管仅采用约 130M 参数的紧凑生成主干，ARPG 仍在 DexJoCo 多任务联合训练中取得优于 $\pi_{0.5}$ (Black et al.,

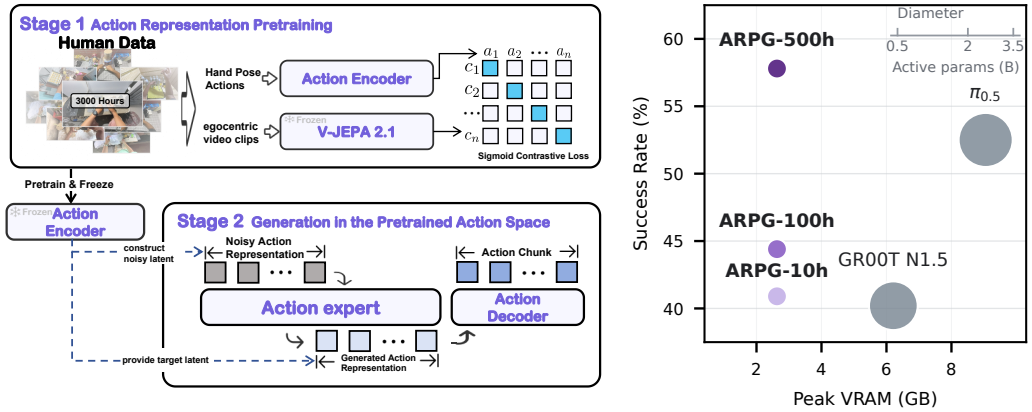


图 1: **ARPG 概览。左:**ARPG 首先利用大规模人类操作数据预训练动作表征, 随后固定动作编码器, 训练机器人策略从加噪动作表征生成未来动作块表征。**右:**比较 DexJoCo 上的平均成功率与峰值推理显存, 散点面积表示推理激活参数量, 具体数值见表 1。

2025a) 的整体性能, 将双手灵巧操作任务的平均成功率从 10.1% 提升至 44.7%, 同时显著降低了推理开销。进一步的扩展实验揭示, 动作表征预训练的有效扩展关键在于扩大预训练数据所覆盖的任务类型。我们还进一步分析了何种动作表征空间更适合复杂动作生成, 验证了视觉–动作对齐所学习表征对下游生成的优势。由此, 动作表征不再只是端到端策略学习过程中联合形成的内部表征, 而可以成为独立预训练和扩展的对象, 为提升复杂灵巧操作能力提供新的扩展路径。

2 相关工作

通用机器人策略(Generalist Robot Policies)。近年来, 视觉–语言–动作模型(VLA)通过将大规模预训练视觉语言模型与机器人数据结合, 将丰富的视觉与语义知识迁移到机器人控制中, 并展现出较强的任务与场景泛化能力 (Black et al., 2025b;a; Zheng et al., 2026b)。近期, 世界动作模型(WAM)进一步利用大规模视频预训练模型, 通过联合建模未来世界状态与动作来引入物理动态与交互先验 (Bi et al., 2026; Ye et al., 2026)。与上述主要面向任务与场景泛化的通用策略不同, ARPG 更关注复杂灵巧操作中的动作生成能力, 并从动作表征探索提升机器人操作能力的另一条路径。

从人类操作数据中学习(Learning from Human Manipulation Data)。由于高质量机器人示范数据昂贵且难以规模化, 近年来大量工作尝试利用人类操作数据扩展机器人学习。一类方法从人类视频中恢复手部、物体或交互轨迹, 并通过动作重定向(retargeting)将其转换为机器人可执行的训练数据 (Yang et al., 2025; Zhang et al., 2026a;b)。另一类方法无需机器人动作标注, 而是从视频状态变化中学习潜在动作(latent actions)或运动标记(motion tokens), 将其作为连接大规模视频预训练与机器人控制的中间监督 (Ye et al., 2025; Chen et al., 2025; Luo et al., 2026b; Routray et al., 2026)。还有一些工作直接利用大规模人类操作数据预训练完整的模型, 再通过机器人数据进行适配 (Luo et al., 2026a; Li et al., 2026; Zheng et al., 2026c)。不同于这些方法, ARPG 将大规模人类操作数据用于动作表征预训练, 从丰富的人类操作经验中学习可复用的双手灵巧操作动作表征。

动作空间学习与生成(Learning Action Spaces for Generation)。生成式机器人策略通常直接在原始连续动作空间中建模复杂的多模态动作分布 (Chi et al., 2023)。为降低高维、高频动作序列的建模难度, 后续工作通过频域压缩、向量量化 (vector quantization) 或动作自编码器 (action autoencoder)构造更紧凑的动作参数化, 并在离散动作标记(action tokens)或学习得到的动作潜空间(latent action spaces)中进行预测与生成 (Lee et al., 2024; Pertsch et al., 2025; Mete et al., 2024; Tan et al., 2025)。上述工作主要通过压缩或重新参数化动作空间来降低策略建模难度, 而较少关注生成空间本身的预训练结构。视觉生成中的相关研究提供了另一种视角:经典潜空间生成方法通常以重建目标学习潜空间 (Rombach et al., 2022), 而近期方法开始显式利用预训练表征来塑造生成空间, 通过对齐生成模型内部特征 (Yu et al., 2025) 或直接采用预训练编码器定义生成空间 (Zheng et al., 2026a; Singh et al., 2026)。受此启发, ARPG 将动作表征作为独立的预训练对象, 并在固定的预训练表征空间中建模下游任务的条件动作分布。

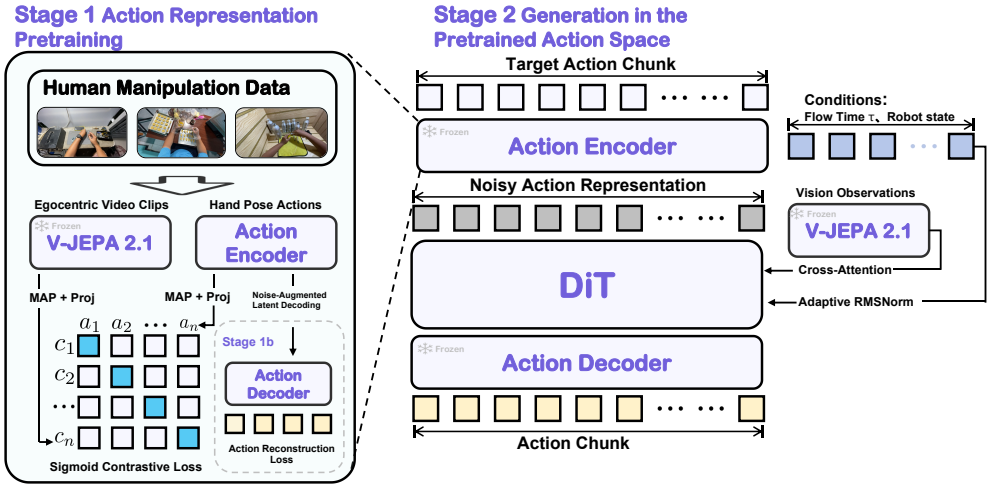


图 2: **ARPG framework**。 **Stage 1a** 在人类操作数据上通过视觉–动作对齐预训练动作编码器; **Stage 1b** 使用目标机器人示范训练动作解码器; **Stage 2** 在固定的动作表征空间中学习条件动作生成。动作编码器仅用于训练目标构造, 不参与推理。

3 动作表征预训练

ARPG 将动作表征学习与下游条件生成显式解耦: 首先独立学习一个具有良好结构且可解码的动作表征空间, 并在后续阶段固定该空间进行动作生成。整体流程如 Figure 2 所示。

3.1 动作表征学习

动作表征空间。给定长度为 T 的连续动作序列 $A = (a_1, \ldots, a_T)$, 其中 a_t 表示第 t 个时间步的动作, 我们学习动作编码器 E_a, 将其映射为时序动作表征 $Z_a = E_a(A) \in \mathbb{R}^{T\times d}$, 其中 d 为表征维度。Z_a 定义了下游生成模型直接建模的动作空间。我们希望该空间同时满足两个要求: 一是具有良好的表征结构, 使复杂动作分布更易建模; 二是保留足够的运动信息, 使其能够被恢复为可执行的连续动作。

仅依赖动作轨迹进行自监督学习需要从头学习表征结构, 而预训练视频模型已经从大规模视频中获得了较丰富的运动与交互结构, 但其视觉表征本身并不能直接作为可解码的动作空间。因此, 我们不直接复用视觉表征, 而是将其作为固定的表征参照, 训练独立的动作编码器与其对齐, 从而在保留动作信息的同时利用大规模视频预训练所提供的结构先验。

视觉–动作双塔模型。给定与动作序列 A 时间同步的操作视频 V, 视觉分支使用冻结的视频编码器 E_v 提取时空视觉特征 $H_v = E_v(V)$。本文将 E_v 实例化为 V-JEPA 2.1 ViT-L/16 (Mur-Labadia et al., 2026), 其作用仅是在表征预训练阶段提供固定的视觉参照, 不参与后续策略推理。动作分支使用 L 层 Transformer 编码连续动作序列, 记第 ℓ 层输出为 $H_a^{(\ell)}$, 其中 $\ell \in \{1, \ldots, L\}$。

受 RAEv2 (Singh et al., 2026) 多层表征聚合设计的启发, 我们利用不同深度特征中的互补信息, 对最后 K 层动作特征分别归一化后进行等权聚合, 得到 $Z_a = \frac{1}{K}\sum_{\ell=L-K+1}^{L} \mathrm{Norm}(H_a^{(\ell)})$, 其中 K 表示参与聚合的层数, $\mathrm{Norm}(\cdot)$ 表示共享的输出 LayerNorm。所得 Z_a 既作为动作解码器的输入, 也定义了后续生成模型的动作空间。具体编码器结构与网络配置见附录 A。

视觉–动作表征对齐。参考 SigLIP (Zhai et al., 2023) 的跨模态表征对齐设计, 我们将其应用于同步的视频–动作数据。对于第 i 个样本, 视觉特征 H_v^i 和动作表征 Z_a^i 分别经过 Multi-head Attention Pooling (MAP) 与独立投影头, 并归一化得到全局视觉表征 v_i 和动作表征 u_i。对于包含 B 个视频–动作样本的 mini-batch, 同一片段对应的 (v_i, u_i) 构成正样本, 其余跨样本组合构成负样本。定义匹配分数 $s_{ij} = \tau v_i^\top u_j + b$, 其中 τ 和 b 分别为可学习的尺度和偏置; 令 $y_{ij} = 1$ 当 $i = j$, 否则 $y_{ij} = -1$。我们优化成对 sigmoid 对齐损失

$$\mathcal{L}_{\text{align}} = -\frac{1}{B}\sum_{i=1}^{B}\sum_{j=1}^{B} \log \sigma(y_{ij} s_{ij}), \tag{1}$$

其中 $\sigma(\cdot)$ 为 sigmoid 函数。训练时仅更新动作编码器 E_a、两侧 MAP 模块及投影头，视觉编码器 E_v 始终冻结；预训练完成后，仅保留 E_a 用于后续动作建模。完整训练配置见附录 E。

3.2 人类操作数据预训练

跨本体动作表征。在 ARPG 中，动作表征学习与下游条件生成相互解耦，因此动作编码器 E_a 无需通过机器人策略的生成目标拟合某一特定机器人本体的控制细节，而可以专注于学习不同操作数据中可复用的运动与交互结构。基于这一点，动作表征预训练不再局限于机器人示范，而可以利用规模更大、行为覆盖更广且更易规模化第一视角人类操作数据学习动作空间，并在后续阶段通过目标机器人示范完成动作解码与条件生成。

统一动作表示。为使不同来源的人类操作数据以及后续机器人数据能够由同一个动作编码器处理，我们将动作轨迹统一转换为固定维度的双手动作表示。具体而言，第 t 个时间步的动作表示为 $a_t = [a_t^L; a_t^R] \in \mathbb{R}^{324}$，其中 a_t^L 和 a_t^R 分别表示左手和右手的 162 维动作槽。每个动作槽包含关节旋转、手掌旋转、绝对腕部位置以及手部关键点相对手腕的位置。关节旋转与关键点位置对手部姿态的冗余描述可为模型提供隐含的手部运动学结构信息。对于缺失或不可用的手部维度，使用有效性掩码进行处理。该统一表示使人手轨迹与不同机器人本体的动作可以被映射到相同的数据接口，而无需改变动作编码器的输入形式。完整的维度定义、动作转换及不同灵巧手的适配方式见附录 B。

人类数据预训练。我们将人类操作数据构造成时间同步的一秒视觉–动作片段：视觉流以 4 Hz 采样得到 4 帧第一视角图像，动作流以 30 Hz 采样得到长度为 $T = 30$ 的动作序列。同步视频 V 与动作序列 A 分别输入冻结的视觉编码器 E_v 和待训练的动作编码器 E_a，并通过第 3.1 节定义的视觉–动作对齐目标进行预训练。预训练数据主要来自 EgoDex (Hoque et al., 2026) 和 EgoVerse (Punamiya et al., 2026)；数据处理、不同预训练规模的构造及优化配置分别见附录 C 和附录 E。

3.3 动作解码器

机器人动作解码。动作表征预训练完成后，我们冻结编码器 E_a，并使用目标机器人示范训练动作解码器 D_a。对于机器人动作序列 A，编码器得到表征 $Z_a = E_a(A)$，解码器进一步预测可执行动作 $\hat{A}_{\text{exec}} = D_a(Z_a)$。$D_a$ 通过带有效性掩码的 Smooth-L_1 重建损失进行优化。统一动作格式及可执行动作定义见附录 B，解码器结构与训练配置见附录 A 和附录 E。

噪声增强解码。参考 RAE (Zheng et al., 2026a) 提出的噪声增强解码设计，为减轻生成动作表征与真实编码表征之间的分布偏移，我们在训练时对 Z_a 施加局部扰动，并使用相同的可执行动作作为监督目标，从而提高解码器对生成误差的鲁棒性。具体扰动方式及训练配置见附录 E。

4 在预训练动作空间中生成

不同于直接生成原始动作，在第 3 节得到预训练动作表征空间后，ARPG 在该固定空间中学习条件动作分布。训练时，动作编码器 E_a 和动作解码器 D_a 均保持冻结，分别用于构造生成目标和恢复可执行动作。

Action Representation Targets. 在时刻 t，记未来动作块为 $A_t = (a_t, \ldots, a_{t+H-1})$，视觉观测为 O_t，机器人状态为 q_t。冻结的动作编码器首先将动作块映射到预训练动作空间，并经归一化得到生成目标 $\bar{Z}_t = N_z(E_a(A_t))$。因此，ARPG 学习条件分布 $p_\theta(\bar{Z}_t \mid O_t, q_t)$，而非直接在原始控制空间中建模 $p(A_t \mid O_t, q_t)$。生成结果经反归一化后，由冻结的动作解码器 D_a 恢复为连续动作。

条件表征生成。我们采用 DiT (Peebles & Xie, 2023) 作为生成骨干，并使用 Flow Matching (Lipman et al., 2023) 进行训练。冻结的 V-JEPA 2.1 (Mur-Labadia et al., 2026) 提取视觉条件 C_t^v，机器人状态形成状态条件 C_t^s。给定高斯噪声 $\epsilon \sim \mathcal{N}(0, I)$ 和流时间 $\tau \in [0, 1]$，构造插值表征 $Z_t^\tau = (1-\tau)\bar{Z}_t + \tau\epsilon$，并优化

$$\mathcal{L}_{\text{FM}} = \mathbb{E}\left[\left\| G_\theta(Z_t^\tau, \tau; C_t^v, C_t^s) - (\epsilon - \bar{Z}_t) \right\|_2^2\right]. \tag{2}$$

训练目标。除 $\mathcal{L}_{\text{FM}}$ 外，我们进一步加入表征级和动作级辅助监督。参考 REPA (Yu et al., 2025)，将 DiT 中间特征 $H_t^{(m)}$ 与冻结动作编码器产生的目标表征对齐，定义 $\mathcal{L}_{\text{REPA}} = \mathbb{E}[\| P_\phi(H_t^{(m)}) - \text{sg}(\bar{Z}_t) \|_2^2]$，其中 P_ϕ 为投影头，$\text{sg}(\cdot)$ 表示停止梯度。此外，$\mathcal{L}_{\text{dec}}$ 约束解码后的动作值，$\mathcal{L}_{\text{smooth}}$ 约束相邻时刻的动作变化。最终训练目标为

$$\mathcal{L} = \lambda_{\text{FM}}\mathcal{L}_{\text{FM}} + \lambda_{\text{REPA}}\mathcal{L}_{\text{REPA}} + \lambda_{\text{dec}}\mathcal{L}_{\text{dec}} + \lambda_{\text{smooth}}\mathcal{L}_{\text{smooth}}. \tag{3}$$

表 1: **DexJoCo 基准上的灵巧操作性能与部署效率比较**。报告单任务与多任务训练下单臂、双臂及全部任务的宏平均成功率(%)以及推理成本。完整的逐任务结果见附录 H。粗体表示各设置下的最佳结果。

方法	推理开销			成功率(%)		
	参数量 (B) ↓	显存 (GB) ↓	延迟 (ms) ↓	单臂 ↑	双手 ↑	总体 ↑
单任务训练						
$\pi_{0.5}$	3.35	9.05	84.9	69.7	35.3	54.1
GR00T N1.5	2.72	6.21	93.6	56.2	21.1	40.2
ARPG	**0.46**	**2.63**	**50.8**	**75.2**	**44.5**	**61.3**
多任务联合训练						
$\pi_{0.5}$	3.35	9.05	84.9	55.8	10.1	35.0
ARPG	**0.46**	**2.63**	**50.8**	**68.8**	**44.7**	**57.8**

推理。从高斯噪声出发, 通过条件速度场生成动作表征, 并经反归一化和冻结的动作解码器 D_a 得到未来动作块。动作编码器 E_a 仅用于训练阶段构造监督目标, 不参与推理。具体求解器和推理配置见附录 E。

5 实验

在本节中, 我们进行广泛的实验, 重点回答以下问题: **Q1.** ARPG 能否在保持下游策略紧凑且高效的同时提升复杂灵巧操作性能, 尤其是双手协同能力?(表 1, 图 3) **Q2.** 应如何扩展动作表征预训练, 以改善下游动作生成?(图 4, 表 1) **Q3.** 在预训练动作空间中进行有效的条件动作生成, 哪些表征与生成建模设计选择至关重要?(表 2)

5.1 实验设置

我们在仿真基准和真实机器人平台上评估 ARPG。完整的训练及评测细节见附录 E、F 和 G。

仿真基准。我们采用 DexJoCo (Wang et al., 2026) 作为主要仿真评测基准。DexJoCo 包含 11 个任务级灵巧操作任务, 其中包括 6 个单臂任务和 5 个双手协同任务。我们遵循其原始任务定义和成功判据, 报告各任务成功率, 并分别计算全部任务、单臂任务和双手任务的宏平均成功率。

真实机器人评测。我们进一步在真实机器人平台上评估三个长序列灵巧操作任务: 传递锤子、倒咖啡豆和开柜取物。每个任务被划分为三个有序阶段, 以刻画策略在长时程执行过程中的阶段性表现。ARPG 与 $\pi_{0.5}$ 使用相同的机器人示范、初始状态分布和成功判据进行评测。

基线。我们比较两个代表性的大规模通用机器人策略: $\pi_{0.5}$ (Black et al., 2025a) 和 GR00T N1.5 (Bjorck et al., 2025)。$\pi_{0.5}$ 代表当前大规模 VLA 路线, 在开放世界泛化和长时程灵巧操作上表现突出; GR00T N1.5 是面向通用人形机器人的大规模基础模型, 支持双臂及灵巧手操作, 并在跨本体操作任务上展现出较强的泛化能力。

5.2 有效且高效的灵巧操作

我们首先研究 **Q1**, 评估 ARPG 在复杂灵巧操作任务上的整体性能以及部署效率, 结果如表 1 和图 3 所示。

Dexterous manipulation performance. 我们在 DexJoCo 上评估 ARPG 的灵巧操作性能, 基线结果采用 Wang et al. (2026) 报告的数值。如表 1 所示, ARPG 在单任务训练下取得了最优的总体成功率(61.3%)。在多任务联合训练下, ARPG 仍达到 57.8%, 而 $\pi_{0.5}$ 降至 35.0%, 两者的性能差距进一步扩大。这一优势在双手灵巧操作中尤为突出: ARPG 在两种训练设置下均保持约 45% 的成功率, 而 $\pi_{0.5}$ 则从 35.3% 降至 10.1%。这一结果表明, 预训练动作表征的优势在复杂多任务生成中尤为突出。通过将动作表征学习与条件生成解耦, ARPG 为下游模型提供了更易建模的动作空间, 从而减轻了多样化动作分布的学习负担。

Deployment efficiency and multi-task scalability. 与此同时, ARPG 以显著更低的激活参数量、峰值显存和推理延迟取得上述性能, 展现出更优的部署效率。这些结果表明, 复杂动作生成的性能提升不必仅依赖扩大生成模型的容量。这进一步体现了独立预训练动作表征的价值: 在实现高性能复杂动作生成的同时, 下游生成模型仍能保持紧凑。

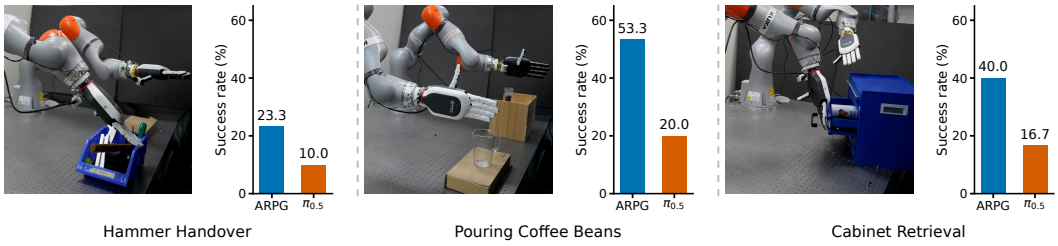


图 3: **真实机器人任务的成功率**。比较 ARPG 与 $\pi_{0.5}$ 在传递锤子、倒咖啡豆和开柜取物三个任务上的表现。每项结果为 30 次测试中成功执行的比例；照片展示对应的任务场景。

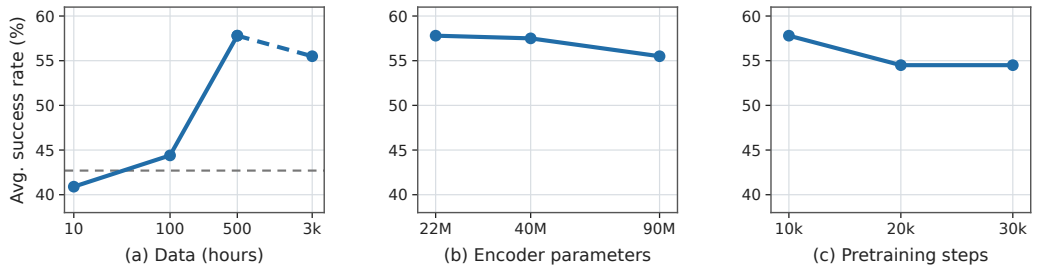


图 4: **动作表征预训练的规模化实验**。分别比较 DexJoCo 平均成功率随 (a) 人类预训练数据量、(b) 动作编码器参数量和 (c) 预训练步数的变化。(b) 的横轴采用以 2 为底的对数尺度。(a) 中，实线连接 10–500 小时结果，蓝色虚线连接 500 与 3,000 小时结果，灰色虚线表示 Robot-only 参照。

Real-world evaluation. 我们进一步在传递锤子、倒咖啡豆和开柜取物三个长时程双手灵巧操作任务上评估 ARPG 的真实机器人性能。如图 3 所示，在相同的机器人示范与评估条件下，ARPG 在三个任务上的完整任务成功率均超过 $\pi_{0.5}$ 。这些结果表明，ARPG 在仿真中展现的复杂动作生成优势，同样能够体现在真实机器人的操作中。

5.3 面向下游生成的动作表征预训练扩展

我们进一步研究 Q2。为此，我们分别从预训练数据、动作编码器规模和预训练计算量三个维度进行扩展，并始终固定其他配置，仅改变动作表征预训练设置。

Pretraining data scaling 我们构建了 10、100、500 和 3,000 小时逐级包含的人类操作数据，并额外使用 DexJoCo 中 8.8 小时的机器人示范预训练一个 Robot-only 编码器作为使用下游域内数据进行预训练的对照。从 10 小时扩展至 500 小时的过程中，新增数据逐步涵盖更多任务与操作行为，数据规模和行为覆盖范围同步扩大；而从 500 小时扩展至 3,000 小时时，新增数据主要集中于已有操作类型，各类操作的样本数量显著增加，但行为覆盖范围的扩展十分有限。具体数据构成见附录 C。

如图 4 所示，随着人类预训练数据从 10 小时扩展至 500 小时，下游成功率从 40.9% 持续提升至 57.8%。相比之下，仅使用 8.8 小时域内机器人数据预训练的编码器取得了 42.7% 的成功率，仍低于使用 100 小时人类数据预训练的结果。而当人类预训练数据进一步增加至 3,000 小时时，在行为覆盖范围基本不变的情况下，下游性能并未获得额外提升。

Behavioral coverage and diminishing returns. 这些结果说明，单纯增加预训练数据量并不必然带来下游性能提升，数据所覆盖的操作行为可能同样是影响动作表征预训练效果的重要因素。我们认为，这一现象可能由以下两个因素造成。首先，我们的对比学习目标将未配对的视频–动作组合视为负样本。因此，当数据中包含大量相似操作行为时，具有相近语义或运动模式的序列也可能形成负样本配对，从而引入潜在的假负样本（false negatives），影响表征学习。其次，增加已有操作行为的样本虽然扩大了数据规模，却未必能提供新的运动模式与交互关系；相比之下，引入新的操作行为有望使编码器接触更丰富的运动与交互结构。因此，在当前实验设置下，扩大预训练数据的行为覆盖范围，可能是比单纯增加已有行为样本数量更值得关注的扩展方向。

表 2: 动作表征与生成设计消融。报告 DexJoCo 上的总体成功率(%)。

(a) 动作表征

表征	总体 ↑
Raw Action	13.3
Action-MAE	36.4
Action-iBOT	30.5
Visual Alignment + iBOT	45.6
Visual Alignment	**57.8**

(b) 聚合深度

Last-K	总体 ↑
1	52.5
2	**57.8**
3	51.6

(c) 辅助训练目标

训练目标	总体 ↑
w/o $\mathcal{L}_{\text{REPA}}$	54.9
w/o $\mathcal{L}_{\text{dec}}$	56.0
Full	**57.8**

Encoder size and pretraining compute. 进一步扩大动作编码器规模或增加预训练计算量未能稳定提升下游成功率。这并不意味着动作表征质量没有改善, 而是表明更充分地优化表征预训练目标, 并不必然得到更适合下游生成的动作表征。一种可能的解释是, 当前预训练目标约束的是经过池化后的序列级视觉–动作对齐(sequence-level vision–action alignment), 而下游 DiT 实际建模的是 token 级时序动作表征(token-level temporal action representations)。因此, 增加模型容量或预训练计算量可能进一步改善全局表征对齐, 却未必增强下游动作生成所依赖的局部时序信息。

5.4 Ablations and Analysis

我们最后研究 **Q3**。为此, 我们固定其他条件, 仅改变动作表征的学习方式, 并进一步消融多层特征聚合和 DiT 训练目标, 结果如表 2(a)–(c) 所示。

Action representation learning. 如表 2(a) 所示, Action-MAE 和 Action-iBOT 相比 Raw Action 均获得提升, 验证了在预训练动作表征空间中进行生成的有效性, 但仅依赖动作轨迹进行表征学习的收益仍然有限。引入 Visual Alignment 后, 下游性能进一步显著提升并取得最佳结果。我们认为, 这一提升主要得益于视觉表征为动作空间提供了一个经过大规模预训练塑造的结构参考:相比需要从头学习表征结构的 action-only self-supervision, Visual Alignment 能够将视觉模型已有的表征结构与交互语义迁移到动作表征中, 同时保留动作解码所需的信息, 因此得到的动作空间更易于下游生成模型建模。

Additional ablations. 我们还对表征构造和下游生成训练中的关键设计进行了消融。如表 2(b) 所示, 使用最后 $K = 1, 2, 3$ 层构造动作表征时, $K = 2$ 取得最佳结果, 支持主模型采用多层深层特征聚合;同时, 表 2(c) 中对 $\mathcal{L}_{\text{REPA}}$ 和 $\mathcal{L}_{\text{dec}}$ 的消融表明, 完整 DiT 训练目标取得最佳下游性能, 验证了这些辅助约束对动作表征生成的有效性。

6 局限与结论

本文提出 ARPG, 将动作表征预训练与下游条件动作生成解耦, 使动作表征能够利用更易扩展的人类操作数据进行预训练, 并为下游策略提供更适于生成的表征空间。实验表明, ARPG 以紧凑的下游策略取得了更高的灵巧操作性能, 并在多任务双手操作中展现出显著优势。规模化实验进一步表明, 扩大预训练数据的操作行为覆盖能够有效提升下游性能。总体而言, ARPG 表明, 可扩展的动作表征预训练为复杂灵巧操作提供了一条独立于机器人示范规模和下游策略容量的扩展路径。

当前工作仍存在若干局限。首先, ARPG 目前仅在灵巧手操作上得到验证, 其对夹爪等不同机器人本体的迁移能力仍有待研究。其次, 本文主要关注复杂动作生成, 尚未系统评估开放环境中的语义理解与任务泛化。此外, 当前预训练的数据与计算规模仍有限, 更大规模下的扩展规律仍需进一步验证。我们将这些方向留待未来工作。

AI 使用声明

在本工作中, 我们使用生成式人工智能工具辅助论文与研究代码的准备。具体而言, 生成式人工智能工具被用于中英文技术文本的翻译与语言润色、论文表述与 LaTeX 文档的辅助编辑, 以及研究代码的软件工程支持, 包括代码阅读、重构、调试和文档整理。所有由人工智能辅助生成或修改的文本、代码和文档均由作者进行审阅; 涉及方法描述、数学表达、文献引用和实验结果的内容均由作者人工核验。生成式人工智能工具未被用作实验数据来源, 也未被用于替代实际的仿真或真实机器人实验; 本文报告的定量实验结果均来自作者实际执行并核验的实验。作者对本文的最终内容承担全部责任, 包括任何借助生成式人工智能产生或修改的文本、代码及其他材料。

伦理声明

本研究使用已有的大规模第一视角人类操纵数据进行动作表征预训练，当前训练语料主要包括 EgoDex 和 EgoVerse。ARPG 仅利用操纵视频以及与手部运动和动作相关的信息学习面向机器人操纵的动作表征，不以身份识别、生物特征识别或敏感属性推断为研究目标。对于第三方人类数据，我们遵循相应数据源规定的访问、使用和再分发条件，并不在本工作中重新分发受原始数据许可或访问条款限制的原始人类视频；与参与者同意、隐私保护及伦理审批相关的信息以原始数据集提供方的官方文档为准。考虑到第一视角视频可能包含隐私敏感的视觉信息，我们将此类数据的使用限制在本研究的操纵表征学习目的以及相应数据源许可的范围内。

本文还包含真实机器人上的灵巧操作实验。此类实验在受控实验环境中进行，并采用实验人员监督、紧急停止机制、机器人关节和工作空间约束、运动速度限制以及机器人平台自身的安全控制机制，以降低意外运动、碰撞和物体损坏等风险。学习策略的输出不会绕过机器人系统原有的安全控制层。我们同时认识到，学习得到的策略在超出本文所评测的机器人本体、任务和环境分布时可能产生不可预期的行为，因此实际部署仍需要针对目标平台进行独立的标定、安全验证和人工监督。本工作的目的在于机器人操纵研究，不涉及身份监控或其他以个人敏感信息为目标的应用。

References

Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Mojtaba Komeili, Matthew Muckley, Ammar Rizvi, Claire Roberts, Koustuv Sinha, Artem Zholus, Sergio Arnaud, Abha Gejji, Ada Martin, Francois Robert Hogan, Daniel Dugas, Piotr Bojanowski, Vasil Khalidov, Patrick Labatut, Francisco Massa, Marc Szafraniec, Kapil Krishnakumar, Yong Li, Xiaodong Ma, Sarath Chandar, Franziska Meier, Yann LeCun, Michael Rabbat, and Nicolas Ballas. V-JEPA 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025. URL https://arxiv.org/abs/2506.09985.

Hongzhe Bi, Hengkai Tan, Shenghao Xie, Zeyuan Wang, Shuhe Huang, Haitian Liu, Ruowen Zhao, Yao Feng, Chendong Xiang, Yinze Rong, Hongyan Zhao, Hanyu Liu, Zhizhong Su, Lei Ma, Hang Su, and Jun Zhu. Motus: A unified latent action world model. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 35101–35113, 2026.

Johan Bjorck, Valts Blukis, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, Joel Jang, Xiaowei Jiang, Kaushil Kundalia, Jan Kautz, Zhiqi Li, Kevin Lin, Zongyu Lin, Loic Magne, Yunze Man, Ajay Mandlekar, Avnish Narayan, Soroush Nasiriany, Scott Reed, You Liang Tan, Guanzhi Wang, Jing Wang, Qi Wang, Shihao Wang, Jiannan Xiang, Yuqi Xie, Yinzhen Xu, Seonghyeon Ye, Zhiding Yu, Yizhou Zhao, Zhe Zhang, Ruijie Zheng, and Yuke Zhu. GR00T N1.5: An improved open foundation model for generalist humanoid robots. NVIDIA Research, 2025. URL https://research.nvidia.com/labs/gear/gr00t-n1_5/.

Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Robert Equi, Chelsea Finn, Niccolo Fusai, Manuel Y. Galliker, Dibya Ghosh, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Devin LeBlanc, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Allen Z. Ren, Lucy Xiaoyang Shi, Laura Smith, Jost Tobias Springenberg, Kyle Stachowicz, James Tanner, Quan Vuong, Homer Walke, Anna Walling, Haohuan Wang, Lili Yu, and Ury Zhilinsky. $\pi_{0.5}$: A vision-language-action model with open-world generalization. In *Proceedings of the 9th Conference on Robot Learning*, volume 305 of *Proceedings of Machine Learning Research*, pp. 17–40. PMLR, 2025a. URL https://proceedings.mlr.press/v305/black25a.html.

Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Robert Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, Szymon Jakubczak, Tim Jones, Liyiming Ke, Sergey Levine, Adrian Li-Bell, Mohith Mothukuri, Suraj Nair, Karl Pertsch, Lucy Xiaoyang Shi, Laura Smith, James Tanner, Quan Vuong, Anna Walling, Haohuan Wang, and Ury Zhilinsky. π_0: A vision-language-action flow model for general robot control. In *Robotics: Science and Systems*, 2025b.

Yi Chen, Yuying Ge, Weiliang Tang, Yizhuo Li, Yixiao Ge, Mingyu Ding, Ying Shan, and Xihui Liu. Moto: Latent motion token as the bridging language for learning robot manipulation from videos. In *IEEE/CVF International Conference on Computer Vision*, pp. 19752–19763, 2025.

Cheng Chi, Siyuan Feng, Yilun Du, Zhenjia Xu, Eric Cousineau, Benjamin Burchfiel, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems*, 2023.

Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.

Ryan Hoque, Peide Huang, David J. Yoon, Mouli Sivapurapu, and Jian Zhang. EgoDex: Learning dexterous manipulation from large-scale egocentric video. In *International Conference on Learning Representations*, 2026. URL https://openreview.net/forum?id=FFxkFMU89E.

Seungjae Lee, Yibin Wang, Haritheja Etukuru, H. Jin Kim, Nur Muhammad Mahi Shafiullah, and Lerrel Pinto. Behavior generation with latent actions. In *International Conference on Machine Learning*, pp. 26991–27008, 2024.

Qixiu Li, Yu Deng, Yaobo Liang, Lin Luo, Lei Zhou, Chengtang Yao, Lingqi Zeng, Zhiyuan Feng, Huizhi Liang, Sicheng Xu, Yizhong Zhang, Xi Chen, Hao Chen, Lily Sun, Dong Chen, Jiaolong Yang, and Baining Guo. Scalable vision-language-action model pretraining for robotic manipulation with real-life human activity videos. In *IEEE International Conference on Robotics and Automation*, 2026. URL https://arxiv.org/abs/2510.21571.

Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023. URL https://openreview.net/forum?id=PqvMRDCJT9t.

Hao Luo, Yicheng Feng, Wanpeng Zhang, Sipeng Zheng, Ye Wang, Haoqi Yuan, Jiazheng Liu, Chaoyi Xu, Qin Jin, and Zongqing Lu. Being-H0: Vision-language-action pretraining from large-scale human videos. In *International Conference on Machine Learning*, 2026a.

Hao Luo, Ye Wang, Wanpeng Zhang, Haoqi Yuan, Yicheng Feng, Haiweng Xu, Sipeng Zheng, and Zongqing Lu. Joint-aligned latent action: Towards scalable VLA pretraining in the wild. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026b.

Atharva Mete, Haotian Xue, Albert Wilcox, Yongxin Chen, and Animesh Garg. QueST: Self-supervised skill abstractions for learning continuous control. In *Advances in Neural Information Processing Systems*, volume 37, 2024.

Lorenzo Mur-Labadia, Matthew Muckley, Amir Bar, Mido Assran, Koustuv Sinha, Mike Rabbat, Yann LeCun, Nicolas Ballas, and Adrien Bardes. V-JEPA 2.1: Unlocking dense features in video self-supervised learning. In *Computer Vision – ECCV 2026*, volume 17005 of *Lecture Notes in Computer Science*, pp. 671–689. Springer, 2026. doi: 10.1007/978-3-032-37369-4_36.

William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 4195–4205, 2023. URL https://openaccess.thecvf.com/content/ICCV2023/html/Peebles_Scalable_Diffusion_Models_with_Transformers_ICCV_2023_paper.html.

Karl Pertsch, Kyle Stachowicz, Brian Ichter, Danny Driess, Suraj Nair, Quan Vuong, Oier Mees, Chelsea Finn, and Sergey Levine. FAST: Efficient action tokenization for vision-language-action models. In *Robotics: Science and Systems*, 2025.

Ryan Punamiya, Simar Kareer, Zeyi Liu, Josh Citron, Ri-Zhao Qiu, Xiongyi Cai, Alexey Gavryushin, Jiaqi Chen, Davide Liconti, Lawrence Y. Zhu, Patcharapong Aphiwetsa, Baoyu Li, Aniketh Cheluva, Pranav Kuppili, Yangcen Liu, Dhruv Patel, Aidan Gao, Hye-Young Chung, Ryan Co, Renee Zbizika, Jeff Liu, Xiaomeng Xu, Haoyu Xiong, Geng Chen, Sebastiano Oliani, Chenyu Yang, Xi Wang, James Fort, Richard Newcombe, Josh Gao, Jason Chong, Garrett Matsuda, Aseem Doriwala, Marc Pollefeys, Robert Katzschmann, Xiaolong Wang, Shuran Song, Judy Hoffman, and Danfei Xu. EgoVerse: An egocentric human dataset for robot learning from around the world. In *Robotics: Science and Systems*, 2026. URL https://arxiv.org/abs/2604.07607.

Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2022.

Sandeep Kumar Routray, Hengkai Pan, Unnat Jain, Shikhar Bahl, and Deepak Pathak. ViPRA: Video prediction for robot actions. In *International Conference on Learning Representations*, 2026.

Jaskirat Singh, Boyang Zheng, Zongze Wu, Richard Zhang, Eli Shechtman, and Saining Xie. Improved baselines with representation autoencoders. *arXiv preprint arXiv:2605.18324*, 2026.

Jianlin Su, Murtadha Ahmed, Yu Lu, Shengfeng Pan, Wen Bo, and Yunfeng Liu. RoFormer: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568:127063, 2024.

Wenhui Tan, Bei Liu, Junbo Zhang, Ruihua Song, and Jianlong Fu. RoLD: Robot latent diffusion for multi-task policy modeling. In *MultiMedia Modeling*, pp. 340–353. Springer, 2025.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, 2017.

Hanwen Wang, Weizhi Zhao, Xiangyu Wang, Siyuan Huang, He Lin, Boyuan Zheng, Rongtao Xu, Gang Wang, Yao Mu, He Wang, Lue Fan, Hongsheng Li, Zhaoxiang Zhang, and Tieniu Tan. DexJoCo: A benchmark and toolkit for task-oriented dexterous manipulation on MuJoCo. *arXiv preprint arXiv:2605.16257*, 2026.

Ruihan Yang, Qinxi Yu, Yecheng Wu, Rui Yan, Borui Li, An-Chieh Cheng, Xueyan Zou, Yunhao Fang, Xuxin Cheng, Ri-Zhao Qiu, Hongxu Yin, Sifei Liu, Song Han, Yao Lu, and Xiaolong Wang. EgoVLA: Learning vision-language-action models from egocentric human videos. *arXiv preprint arXiv:2507.12440*, 2025.

Seonghyeon Ye, Joel Jang, Byeongguk Jeon, Sejune Joo, Jianwei Yang, Baolin Peng, Ajay Mandlekar, Reuben Tan, Yu-Wei Chao, Yuchen Lin, Lars Liden, Kimin Lee, Jianfeng Gao, Luke Zettlemoyer, Dieter Fox, and Minjoon Seo. Latent action pretraining from videos. In *International Conference on Learning Representations*, 2025.

Seonghyeon Ye, Yunhao Ge, Kaiyuan Zheng, Shenyuan Gao, Sihyun Yu, George Kurian, Suneel Indupuru, You Liang Tan, Chuning Zhu, Jiannan Xiang, Ayaan Malik, Kyungmin Lee, William Liang, Nadun Ranawaka, Jiasheng Gu, Yinzhen Xu, Guanzhi Wang, Fengyuan Hu, Avnish Narayan, Johan Bjorck, Jing Wang, Gwanghyun Kim, Dantong Niu, Ruijie Zheng, Yuqi Xie, Jimmy Wu, Qi Wang, Ryan Julian, Danfei Xu, Yilun Du, Yevgen Chebotar, Scott Reed, Jan Kautz, Yuke Zhu, Linxi Fan, and Joel Jang. World action models are zero-shot policies. *arXiv preprint arXiv:2602.15922*, 2026. URL https://arxiv.org/abs/2602.15922.

Sihyun Yu, Sangkyung Kwak, Huiwon Jang, Jongheon Jeong, Jonathan Huang, Jinwoo Shin, and Saining Xie. Representation alignment for generation: Training diffusion transformers is easier than you think. In *International Conference on Learning Representations*, 2025. URL https://proceedings.iclr.cc/paper_files/paper/2025/hash/d9e42b4d7163931f3689d6d6fbaa11d0-Abstract-Conference.html.

Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *International Conference on Computer Vision*, 2023.

Gu Zhang, Qicheng Xu, Haozhe Zhang, Jianhan Ma, Long He, Yiming Bao, Zeyu Ping, Zhecheng Yuan, Chenhao Lu, Chengbo Yuan, Tianhai Liang, Xiaoyu Tian, Maanping Shao, Feihong Zhang, Mingyu Ding, Yang Gao, Hao Zhao, Hang Zhao, and Huazhe Xu. UniDex: A robot foundation suite for universal dexterous hand control from egocentric human videos. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026a.

Yuhong Zhang, Zihan Gao, Shengpeng Li, Ling-Hao Chen, Kaisheng Liu, Runqing Cheng, Xiao Lin, Junjia Liu, Zhuoheng Li, Jingyi Feng, Ziyan He, Jintian Lin, Zheyan Huang, Zhifang Liu, and Haoqian Wang. RoboWheel: A data engine from real-world human demonstrations for cross-embodiment robotic learning. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2026b.

Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Proceedings of Robotics: Science and Systems*, 2023. doi: 10.15607/RSS.2023.XIX.016. URL https://roboticsproceedings.org/rss19/p016.html.

Boyang Zheng, Nanye Ma, Shengbang Tong, and Saining Xie. Diffusion transformers with representation autoencoders. In *International Conference on Learning Representations*, 2026a.

Jinliang Zheng, Jianxiong Li, Zhihao Wang, Dongxiu Liu, Xirui Kang, Yuchun Feng, Yinan Zheng, Jiayin Zou, Yilun Chen, Jia Zeng, Ya-Qin Zhang, Jiangmiao Pang, Jingjing Liu, Tai Wang, and Xianyu Zhan. X-VLA: Soft-prompted transformer as scalable cross-embodiment vision-language-action model. In *International Conference on Learning Representations*, 2026b.

Ruijie Zheng, Dantong Niu, Yuqi Xie, Jing Wang, Mengda Xu, Yunfan Jiang, Fernando Castañeda, Fengyuan Hu, You Liang Tan, Letian Fu, Trevor Darrell, Furong Huang, Yuke Zhu, Danfei Xu, and Linxi Fan. EgoScale: Scaling dexterous manipulation with diverse egocentric human data. *arXiv preprint arXiv:2602.16710*, 2026c.

Jinghao Zhou, Chen Wei, Huiyu Wang, Wei Shen, Cihang Xie, Alan Yuille, and Tao Kong. iBOT: Image BERT pre-training with online tokenizer. In *International Conference on Learning Representations*, 2022.

Yi Zhou, Connelly Barnes, Jingwan Lu, Jimei Yang, and Hao Li. On the continuity of rotation representations in neural networks. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 5745–5753, 2019.

A 架构细节

A.1 动作编码器

动作编码器 E_a 采用 Transformer (Vaswani et al., 2017) 对连续双手动作序列进行时序建模。对于一个长度为 $T = 30$ 的动作片段 $A \in \mathbb{R}^{30\times 324}$, 每个时间步的动作首先按照双手的解剖结构进行分组编码, 随后映射为帧级 action token。经过多层 Transformer 编码后, 末端多个层级的特征被聚合为最终动作表征 $Z_a \in \mathbb{R}^{30\times 512}$。

动作 token 化。每帧 324 维动作按照左右手分别划分为手腕及五根手指, 共 12 个动作组。每个动作组首先通过独立的线性层与 GELU 激活映射为 32 维局部特征, 随后拼接 12 组特征, 并进一步投影为 512 维 action token。无效动作维度在 token 化前置零; 当整个时间步无有效动作时, 对应 token 在时序注意力中被 mask。

Transformer 编码器。动作编码器包含 8 个 Transformer blocks, hidden dimension 为 512, 采用 8 个 attention heads, MLP ratio 为 4, dropout 为 0.1, 并使用 rotary positional embedding (Su et al., 2024) 编码时间位置信息。

多层动作表征。为利用深层 Transformer 中互补的动作信息, 我们分别对最后 K 层输出施加共享的 LayerNorm, 并沿网络深度进行等权聚合:

$$E_a(A) = \frac{1}{K} \sum_{\ell=L-K+1}^{L} \mathrm{Norm}\left(H_a^{(\ell)}\right). \tag{4}$$

主模型采用 $K = 2$, 即聚合最后两个 Transformer blocks 的输出, 最终得到 $Z_a \in \mathbb{R}^{30\times 512}$。

序列池化与投影。在动作表征预训练阶段, 视觉分支和动作分支分别采用独立的 Multi-head Attention Pooling(MAP)模块将 token sequence 聚合为序列级表示。每个 MAP 模块使用一个可学习 query, 并分别对 query 与输入 token 进行 LayerNorm, 再通过 8-head cross-attention 完成序列聚合。视觉侧的 1024 维 pooled feature 与动作侧的 512 维 pooled feature 分别经过独立的线性 projection head 映射到共享的 512 维空间, 并进行 ℓ_2 normalization。

A.2 动作编码器训练目标

给定时间同步的第一视角视频片段 V_i 与动作序列 A_i, 冻结的 V-JEPA 2.1 编码器 (Mur-Labadia et al., 2026) 产生视觉 token, 动作编码器产生对应的 action tokens。两个分支分别经过 MAP 和 projection head 后得到归一化的序列级表示 v_i 和 a_i。本文主模型采用 Visual Alignment 作为动作表征预训练目标。

视觉–动作对齐。对于包含 B 个同步视频–动作序列对的 mini-batch, 同一片段对应的视觉与动作表示构成正样本, 其余全部跨序列组合构成负样本。视觉表示 v_i 与动作表示 a_j 的匹配分数为

$$s_{ij} = \tau v_i^\top a_j + b, \tag{5}$$

其中 τ 和 b 为可学习参数。动作编码器通过 pairwise sigmoid objective (Zhai et al., 2023) 学习与视觉交互过程一致的动作结构。训练过程中, V-JEPA 2.1 保持冻结, 仅更新动作编码器、MAP 模块和 projection head。

Action-MAE。 Action-MAE (He et al., 2022) 使用与主方法相同的动作 tokenization 和 Transformer encoder, 但不使用配对视频监督。训练时随机遮蔽有效动作组, 并使用训练阶段专用的重建解码器预测被遮蔽的原始动作。该解码器将编码后的 30 个 latent tokens 与 30 个带时间嵌入的可学习 query tokens 拼接, 经 4 层、hidden dimension 为 512、8 个 attention heads 的 pre-norm Transformer 处理, 再由 LayerNorm 和线性层输出 30×324 维动作; 重建损失仅作用于有效且被遮蔽的动作维度。重建目标由 Smooth-L_1 reconstruction loss 与 temporal velocity loss 组成, 用于学习动作序列内部的局部结构与时序变化。

Action-iBOT。 Action-iBOT 同样保持动作 tokenizer 与 Transformer encoder 不变, 仅采用动作侧 masked self-distillation (Zhou et al., 2022)。训练时遮蔽 50% 的有效动作内容, 并利用 teacher–student prediction 学习 masked action tokens 的表征。Projection head 使用 2,048 维 hidden layer 和 256 维 bottleneck, 并预测 8,192 个 prototypes; 其 teacher update、temperature schedule 等训练配置见附录 E。

Visual Alignment。 Visual Alignment 仅使用视觉–动作 sigmoid alignment, 不引入动作侧 masked self-distillation。该设置利用同步人类操作视频提供的运动与交互语义约束动作表征空间。

Visual Alignment + iBOT。 Visual Alignment + iBOT 联合使用视觉–动作对齐和动作侧 masked self-distillation, 在利用跨模态交互信息的同时保留动作序列内部的自监督学习信号。

Raw Action。 Raw Action 不使用预训练动作编码器与动作解码器, 生成模型直接在机器人可执行动作空间中预测连续动作, 用于比较原始动作空间与预训练表征空间中的条件动作生成。

A.3 动作解码器

动作解码器 D_a 将动作编码器产生的 latent sequence 映射回机器人控制接口所需的连续动作。其输入为 $Z_a \in \mathbb{R}^{30\times 512}$, 输出为长度相同的双手可执行动作序列 $\hat{A}_{\text{exec}} \in \mathbb{R}^{30\times 198}$。

Latent memory 与 query tokens。对于 30 个 latent tokens, 解码器引入 30 个带时间索引的可学习 query tokens, 并将 latent memory 与 query tokens 拼接。两类 token 分别加入 token-type embedding 和 temporal embedding。

Transformer decoder。拼接后的序列由 5 层 pre-norm Transformer 处理。Decoder hidden dimension 为 512, 采用 8 个 attention heads, MLP ratio 为 4, dropout 为 0.1。

动作输出。最终仅保留 query-token features, 并经过 LayerNorm 和线性 prediction head 生成 $[30, 198]$ 的连续动作序列。198 维输出由左右手各自 99 维可执行动作拼接而成:

$$\hat{A}_{\text{exec}} = [\hat{A}^{L}_{0:99}; \hat{A}^{R}_{0:99}] \in \mathbb{R}^{30\times 198}. \tag{6}$$

统一动作表示中额外的 126 维 wrist-relative keypoint positions 不由动作解码器输出, 其具体定义见附录 B。

A.4 生成主干

下游策略采用 conditional DiT (Peebles & Xie, 2023), 在冻结动作编码器定义的表示空间中生成未来动作 latent。动作 latent sequence 作为生成模型的主序列, 多视角视觉 token 通过 cross-attention 注入生成主干, 机器人本体状态与 flow time 则作为全局条件对动作特征进行调制。

DiT backbone。生成主干包含 10 个 Transformer blocks, hidden dimension 为 768, 采用 12 个 attention heads, MLP ratio 为 4, 使用 bidirectional self-attention、temporal rotary positional embedding 和零 dropout。输入和输出 projection 分别完成 512 维动作 latent 与 768 维 DiT hidden feature 之间的转换。主序列包含 30 个 latent tokens, 对应 1 s、30-step 的未来动作 chunk。

视觉条件。 ARPG 使用第一视角相机和左右腕部相机三个视角。每个视角输入连续 2 帧 384×384 RGB 图像, 并由冻结的 V-JEPA 2.1 ViT-L/16 编码。tubelet size 为 2、空间 token grid 为 24×24, 因此每个视角得到 576 个 1024 维视觉 tokens。三个固定视角分别加入独立的可学习 camera embedding, 随后将视觉 tokens 拼接, 并在每个 DiT block 中通过 cross-attention 注入动作 latent sequence。

机器人状态条件。 324 维机器人本体状态首先通过三层 GELU MLP 映射至 768 维条件特征。

Flow-time 条件。Flow Matching 时间 τ 使用 sinusoidal embedding 编码, 并与机器人状态特征联合输入两层 SiLU modulation network。调制网络为每个 DiT block 产生 adaptive RMSNorm 所需的 shift、scale 与 residual gate, 从而将当前机器人状态和 flow time 注入 self-attention 与 feed-forward 子层。

中间表征对齐。 REPA supervision (Yu et al., 2025) 施加于第 4 个 DiT block 的中间特征。该特征经过 RMSNorm 后, 通过线性 projection head 映射至 512 维, 并与冻结动作编码器产生的 clean action representation 对齐。其损失权重及其他辅助监督配置见附录 E。

B 统一动作格式(Unified Action Format)

为统一人类操作数据与不同机器人平台的动作形式, 我们将所有动作轨迹转换为固定维度的双手动作格式 $A \in \mathbb{R}^{T\times 324}$。每只手对应一个 162 维动作槽位, 由局部关节旋转、手掌旋转、绝对手腕位置以及手腕相对关键点组成。所有旋转均采用连续 6D 表示 (Zhou et al., 2019), 位置以米为单位; 手部关键点相对于手腕进行表示, 使全局平移信息集中在绝对手腕位置中。左右手使用相同的动作布局, 并通过有效性 mask 处理缺失或不可用的动作维度。

表 3: 统一动作格式的具体布局。索引采用从零开始的左闭右开区间。

手	动作分量	索引范围	维度	解码器输出
左手	15 个局部关节旋转(6D)	$[0, 90)$	90	是
左手	手掌旋转(6D)	$[90, 96)$	6	是
左手	绝对手腕位置	$[96, 99)$	3	是
左手	21 个手腕相对关键点	$[99, 162)$	63	否
右手	15 个局部关节旋转(6D)	$[162, 252)$	90	是
右手	手掌旋转(6D)	$[252, 258)$	6	是
右手	绝对手腕位置	$[258, 261)$	3	是
右手	21 个手腕相对关键点	$[261, 324)$	63	否

动作格式。单只手的 162 维动作由 15 个局部关节旋转、手掌旋转、绝对手腕位置和 21 个手腕相对关键点组成。左右手两个 162 维槽位拼接后形成完整的 324 维动作输入。各分量的具体布局如下表所示, 其中索引采用从零开始的左闭右开区间。

可执行动作。完整的 324 维动作被输入动作编码器, 用于学习同时包含运动学状态与局部手部几何信息的动作表征。其中, 每只手最后 63 维的手腕相对关键点仅作为动作表征学习的辅助几何信息, 而不属于机器人控制接口所需的直接控制量。因此, 动作解码器仅预测每只手前 99 维动作, 并将左右手输出拼接为

$$A_{\text{exec}} = [A^L_{0:99}; A^R_{0:99}] \in \mathbb{R}^{T\times 198}. \tag{7}$$

因此, 324 维统一动作格式用于动作编码与表征学习, 而策略最终输出并发送至机器人控制器的是 198 维可执行动作;额外的 126 维手腕相对关键点不作为控制命令输出。

灵巧手适配。为适配不同结构的灵巧手, 我们使用固定的双手动作槽位, 并通过有效性 mask 处理缺失或不可用的动作维度。对于 DexJoCo 中使用的四指 Allegro 手, 我们利用 MuJoCo 正向运动学构造统一动作格式所需的手腕相对关键点, 不存在的第五根手指对应维度置零并标记为无效;这些无效维度在相关训练损失计算中被忽略。

C 人类操作预训练数据(Human Manipulation Pretraining Data)

动作编码器的预训练语料由 EgoDex 和 EgoVerse 两个大规模第一视角人类操作数据集构成, 包含时间同步的第一视角视频与三维手部运动轨迹。我们将不同数据源统一转换为长度为 1 s 的视觉–动作片段:视觉流以 4 Hz 采样得到 4 帧第一视角图像, 动作流以 30 Hz 采样得到 30 帧连续动作, 并转换为附录 B 所定义的 324 维统一动作格式。人类操作数据仅用于动作编码器的表征预训练;动作解码器和下游生成策略均仅使用目标机器人示范进行训练。

C.1 主要数据集

EgoDex。 EgoDex (Hoque et al., 2026) 提供第一视角人类操作视频, 以及通过 Apple Vision Pro 采集的三维手部与手指运动轨迹。我们使用第一视角 RGB 视频及其对应的手部轨迹构造同步的视觉–动作训练样本, 数据集中的任务标签不作为动作编码器的输入。

EgoVerse。 EgoVerse (Punamiya et al., 2026) 提供面向机器人学习的跨地域第一视角操作视频及手部运动轨迹。对于仅有单手被完整跟踪的片段, 我们保留有效手的动作轨迹, 并通过附录 B 中的有效性 mask 处理缺失的另一只手, 而不直接丢弃整个片段。

C.2 数据筛选

两个数据源采用一致的动作转换与质量控制流程。我们使用 0.05 的手部跟踪置信度阈值, 并要求每帧至少包含 12 个有效关节。对于正向运动学重建误差超过 0.02 m 或相邻帧旋转变化超过 90° 的样本, 将对应帧标记为无效。为降低手部跟踪产生的高频抖动, 我们在连续有效的动作区间内采用 5 帧时间平滑, 并避免跨越缺失手部的时间区间进行插值或平滑。经过转换和质量控制后, 所有有效轨迹进一步切分为统一的 1 s 训练片段。

C.3 训练数据规模

我们从同一转换后的数据池构建 10、100、500 和 3,000 小时的人类操作预训练数据, 并保持动作格式、数据预处理流程和模型架构不变。在数据规模对比中, 各规模均采用固定的预训练优化步数, 因此训练

表 4: 不同规模的人类操作预训练数据的规模与任务分布。

指标	500 h	3,000 h
片段累计时长	500 h 20 m 16 s	3,088 h 16 m 59 s
总样本数	1,801,216	11,117,819
任务种类数	17,382	23,316
最大单任务占比	0.09%	9.85%
Top-10 任务占比	0.77%	23.87%
平均样本/任务	103.63	476.83
中位数样本/任务	39	54
P90 样本/任务	213	453
EgoDex / EgoVerse 比例	22.00% / 78.00%	22.01% / 77.99%

轮数随数据集大小而变化；表 6 中的 3 轮仅对应完整的 3,000 小时数据集。我们对完整 data shard 采用确定性顺序，逐级累积构建数据集：10 小时数据中的所有片段保留在 100 小时数据中，100 小时数据中的所有片段保留在 500 小时数据中，500 小时数据则包含在完整的 3,000 小时数据中。每次扩展仅增加 shard，不移除已有片段；500 小时数据同时近似保持两个数据源在完整数据池中的组成比例。完整数据集包含 11,117,819 个 1 s 训练片段。其约 3,088 小时（正文简称 3,000 小时）是片段时长的累加值，而非互不重叠的原始视频时长；如有重叠片段，则分别计入该总时长。

D 机器人示范与下游数据（Robot Demonstrations and Downstream Data）

动作解码器与下游生成策略均仅使用目标机器人示范进行训练。对于仿真实验，我们采用 DexJoCo 提供的机器人示范；对于真实机器人实验，我们在双臂灵巧手平台上采集三项长时程操作任务的数据。不同平台的机器人动作均转换为附录 B 所定义的统一动作格式，并使用相同的数据接口提供视觉观测、机器人本体状态与未来动作目标。

D.1 DexJoCo 数据

DexJoCo (Wang et al., 2026) 包含约 1.1K 条机器人示范，覆盖 11 个灵巧操作任务。我们采用官方的 `rand-obj` 设置，其中包含 6 个单臂任务和 5 个双臂任务。仿真平台由 Franka Panda 机械臂与 Wonik Allegro 灵巧手组成。

- **单臂任务：** Hammer Nail、Click Mouse、Pick Bucket、Pinch Tongs、Fold Glasses 和 Water Plant。
- **双臂任务：** Unlock iPad、Hanoi、Assembly、Microwave 和 Photograph。

我们遵循 DexJoCo 官方示范数据与环境配置，并将原始机器人轨迹转换为统一的训练格式。每个时间步包含第一视角相机和左右腕部相机的视觉观测、机器人本体状态、动作目标以及对应的有效性 mask。原始 TCP 目标与 Allegro 手部控制量进一步转换为 324 维统一动作格式，以用于动作编码器、动作解码器和下游生成策略的训练。

D.2 真机数据采集硬件

真实机器人平台由两台 7-DoF KUKA iiwa 机械臂和两只 12-DoF DexHand 灵巧手组成。视觉观测由三个相机视角提供，包括一台 Intel RealSense L515 场景相机和分别安装于左右机械臂末端的两台 Intel RealSense D405 腕部相机。L515 以 960×540 分辨率记录场景视角，两台 D405 以 640×480 分辨率记录腕部视角。机器人状态与多相机图像在数据记录阶段进行时间同步，机器人状态与视觉帧之间允许的最大时间偏差为 50 ms。

D.3 真机数据内容

我们采集三项长时程双手灵巧操作任务的机器人示范：Hammer Handover、Pouring Coffee Beans 和 Cabinet Retrieval。每条示范记录同步的三视角 RGB 图像、双臂关节状态、双手状态以及对应的动作目标，并统一转换为附录 B 中的 324 维动作格式。每项任务的数据规模如下：

表 5: 三项真机任务的数据规模。数据时长为估算的原始采集时长(h:mm:ss)。

任务	任务内容	示范数量	数据时长
Hammer Handover	拿取锤子、双手交接并完成放置	40	3:19:31
Pouring Coffee Beans	拿取容器并完成咖啡豆倾倒	40	2:15:03
Cabinet Retrieval	打开柜门、取出目标物体并关闭柜门	40	1:47:31
总计	—	**120**	**7:22:05**

表 6:动作表征预训练的超参数。

Pretraining objective	Visual Alignment
Optimizer	AdamW
Batch size	1,536
Learning rate	2×10^{-4}
Minimum learning rate	2×10^{-6}
Weight decay	0.05
Warmup steps	1,000
LR schedule	Cosine
Training steps	21,714
Training epochs	3
Precision	bfloat16
Gradient clipping	1.0
MAP attention heads	8
Projection dimension	512
Initial logit scale	10
Initial bias	-10

表 7:下游策略训练的超参数。

Optimizer	AdamW
Batch size	128
Learning rate	1×10^{-4}
Minimum learning rate	1×10^{-6}
Weight decay	0.05
Warmup steps	500
LR schedule	Cosine
Training steps	120,000
Precision	bfloat16
Gradient clipping	1.0
EMA decay	0.9999
Flow-time sampling	$0.999\,\mathrm{Beta}(1.5, 1) + 0.001$
λ_{FM}	1.0
λ_{REPA}	0.5
λ_{dec}	1.0
$\lambda_{\mathrm{smooth}}$	0.01
ODE solver	Euler
Inference steps	10

所有真实机器人示范均使用手部动捕设备采集。动作解码器与下游策略使用相同的目标机器人示范数据, 分别学习 latent-to-action 映射和任务条件下的动作生成分布。表中时长根据处理后训练数据的帧数及 30 Hz 帧率计算, 再乘以 3 估计剪辑、加速前的原始时长。

E 训练细节

动作编码器预训练。动作编码器采用 Visual Alignment 进行预训练。冻结的 V-JEPA 2.1 提供视觉表征, 训练过程中仅优化动作编码器、视觉与动作两侧的 MAP 模块以及 projection heads。对于一个包含 B 个同步视频–动作片段的 mini-batch, 同一片段对应的视觉–动作 pair 作为正样本, 其余跨片段组合均作为负样本, 并使用 pairwise sigmoid objective 进行优化。主要训练超参数汇总于表 6。

下游生成策略训练。动作编码器和动作解码器在下游策略训练期间均保持冻结。Conditional DiT 使用冻结动作编码器产生的 action representation 作为 Flow Matching 的生成目标, 并以视觉观测和机器人本体状态为条件学习未来动作 latent 的条件分布。除主要的 Flow Matching objective 外, 我们还采用 REPA representation alignment、decoded-action supervision 和 trajectory smoothness supervision。主要训练与推理配置汇总于表 7。

动作解码器训练。动作编码器预训练完成后保持冻结, 动作解码器仅使用目标机器人示范进行训练。给定动作序列 A, 冻结编码器首先得到动作 latent $Z_a = E_a(A)$, 随后解码器预测附录 B 所定义的 198 维可执行动作。解码器采用带有效性 mask 的 Smooth-L_1 reconstruction loss, 无效动作维度不参与损失计算。

为增强解码器对生成 latent 偏移的鲁棒性,我们在标准化后的 latent space 中采用 noise-augmented decoding。对于每个样本, 首先采样

$$\sigma \sim \mathcal{U}(0, \delta), \qquad \epsilon \sim \mathcal{N}(0, \sigma^2 I), \tag{8}$$

并将扰动后的 latent

$$\widetilde{Z}_a = Z_a + \epsilon \tag{9}$$

输入解码器。25% 的训练样本保持 clean latent;最大噪声尺度 δ 在前 5,000 个训练步内从 0 线性增加至 0.05。解码器使用 AdamW 训练 100,000 steps, batch size 为 512, 学习率为 2×10^{-4}, weight decay 为 0.05; 前 1,000 steps 采用 linear warmup, 随后使用 cosine schedule 衰减至 2×10^{-6}。训练采用 bfloat16 mixed precision, 并将 gradient norm 裁剪至 1.0。

辅助训练目标。下游策略的完整训练目标为

$$\mathcal{L} = \lambda_{\mathrm{FM}}\mathcal{L}_{\mathrm{FM}} + \lambda_{\mathrm{REPA}}\mathcal{L}_{\mathrm{REPA}} + \lambda_{\mathrm{dec}}\mathcal{L}_{\mathrm{dec}} + \lambda_{\mathrm{smooth}}\mathcal{L}_{\mathrm{smooth}}. \tag{10}$$

其中，$\mathcal{L}_{\text{REPA}}$ 将 DiT 中间特征与冻结动作编码器产生的 clean action representation 对齐；$\mathcal{L}_{\text{dec}}$ 直接监督生成 latent 解码后的可执行动作；$\mathcal{L}_{\text{smooth}}$ 则约束相邻时间步之间的动作变化。所有 action-space losses 均使用对应的有效性 mask；对于 smoothness loss，当相邻两个时间步中任一动作维度无效时，对应 pair 不参与损失计算。

F 仿真实验细节（Simulation Experiment Details）

训练设置。我们在 DexJoCo 的 `rand-obj` 设置下分别进行单任务训练和多任务联合训练。单任务设置中，每个任务使用对应的机器人示范独立训练一个策略，共训练 60,000 steps；多任务设置则联合使用全部 11 个任务的数据，并训练 120,000 steps。两种设置使用相同的模型架构和优化配置，具体训练超参数见附录 E。

多任务训练过程中，不额外构建验证集，最终评测使用 120,000 steps 的 checkpoint。多任务训练使用按任务组织的 shard-local batch sampler，在每个 shard group 内无放回地抽取样本，并优先在 mini-batch 中覆盖不同任务；该实现不强制各任务的全局采样概率相等。

基线实现。我们将 ARPG 与 DexJoCo 中报告的 $\pi_{0.5}$ 和 GR00T N1.5 进行比较。为避免重新训练大型通用策略所引入的额外实现差异，基线结果均采用 DexJoCo 官方在相同 `rand-obj` 设置下报告的数值 (Wang et al., 2026)。

- $\pi_{0.5}$**.** 单任务和多任务结果均采用 DexJoCo 官方报告的结果。
- **GR00T N1.5.** 单任务结果采用 DexJoCo 官方报告的结果。
- **ARPG.** 所有 ARPG 结果均使用本文的动作格式转换和训练流程重新训练，并分别在单任务和多任务设置下进行评测。

评测协议。所有方法均遵循 DexJoCo 的官方环境设置和任务成功判定。对于每个任务，我们使用随机种子 0、1 和 2 分别进行评测，每个随机种子运行 50 个 episodes，共计 150 个 rollouts。逐任务结果报告三个随机种子成功率的均值与标准差。

对于单臂任务、双臂任务及全部任务，我们分别计算无权 macro-average：

$$S_{\text{single}} = \frac{1}{6}\sum_{i=1}^{6} S_i, \qquad S_{\text{bimanual}} = \frac{1}{5}\sum_{i=1}^{5} S_i, \qquad S_{\text{all}} = \frac{1}{11}\sum_{i=1}^{11} S_i. \tag{11}$$

策略与控制频率均为 30 Hz。每次策略查询生成一个 30-step action chunk，推理调度器使用 8-step 的名义执行窗口进行滚动重规划。评测配置采用 strict RTC（PI-VJP）执行，并利用上一 action chunk 进行推理时 guidance；prefix-attention schedule 为 exponential，最大 guidance weight 为 5.0，推理延迟安全余量为 40 ms。

G 真机实验细节（Real-World Experiment Details）

任务设置。我们在三个需要连续执行多个操作阶段的真实机器人任务上评估策略，包括 Hammer Handover、Pouring Coffee Beans 和 Cabinet Retrieval。每个任务被划分为三个按顺序完成的阶段，以同时衡量策略的局部操作能力和长时程任务完成能力。

三个真机任务的执行过程分别见图 5、图 6 和图 7。每张图中的六帧按从左至右、从上至下的顺序排列。

对于每个 rollout，只有在前一阶段成功完成后才进一步统计后续阶段的完成情况；最终任务成功要求依次完成全部三个阶段。**评测协议**。 ARPG 与 $\pi_{0.5}$ 使用相同的机器人示范、初始状态分布和任务成功判据进行训练与评测。

每个阶段的成功率按照达到该阶段成功条件的 rollout 比例计算，最终成功率则按照完成全部三个阶段的 rollout 比例计算。对于方法 m 和阶段 k，阶段成功率定义为

$$S_{m,k} = \frac{N_{m,k}^{\text{success}}}{N_{m}^{\text{rollout}}}. \tag{12}$$

基线设置。真机实验主要与 $\pi_{0.5}$ 进行比较。为保证比较的一致性，$\pi_{0.5}$ 与 ARPG 使用完全相同的机器人示范数据，并在相同的三视角视觉输入、初始状态分布和成功判据下进行评测。对于 $\pi_{0.5}$，我们从 $\pi_{0.5}$ 基础权重初始化，采用混合 LoRA 微调；训练配置设为 25,000 steps、batch size 32、1,000-step

表 8: 真机评测任务的阶段定义。

任务	Stage 1	Stage 2	Stage 3
Hammer Handover	抓起锤子	完成双手交接	将锤子放置到目标位置
Pouring Coffee Beans	拿起装有咖啡豆的容器	成功将咖啡豆倒出	将咖啡豆完全倒出
Cabinet Retrieval	打开柜门	从柜中取出目标物体	关闭柜门

注:每个任务的三个阶段均需按顺序完成。

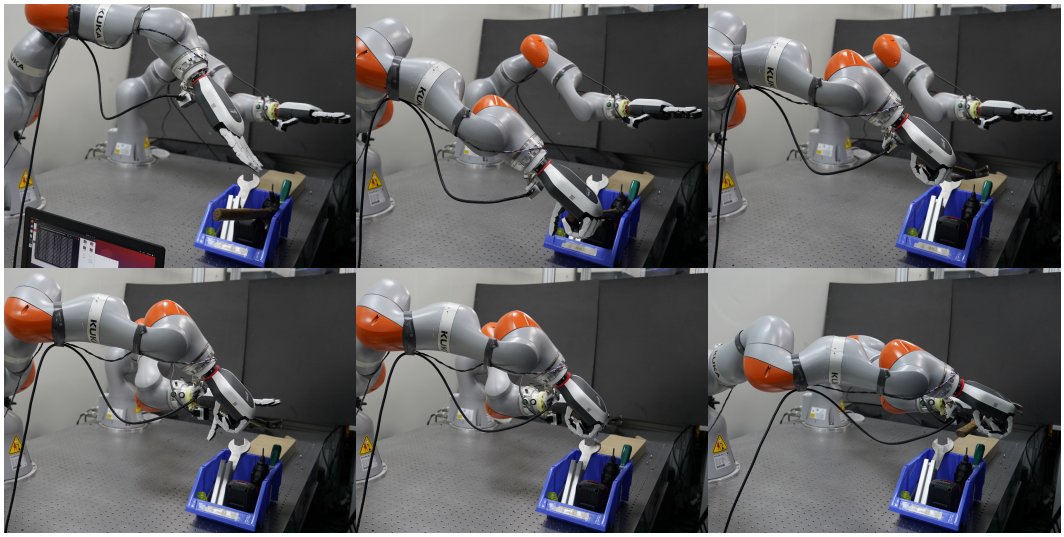


图 5: **Hammer Handover 具体流程**。右手拾取锤子、交给左手, 并由左手放下。

warmup, 并每 1,000 steps 保存 checkpoint。模型输入包含三视角图像、任务语言指令和 38 维归一化机器人状态; 设置 `discrete_state_input=True`, 将状态离散化后加入语言 prompt, 并设置 `max_token_len=250`。三项任务的指令分别描述右手拾取锤子、交给左手并放下; 双手拿起量杯并将左侧量杯中的咖啡豆倒入右侧量杯; 右手打开柜门、左手取出物体、右手关闭柜门。

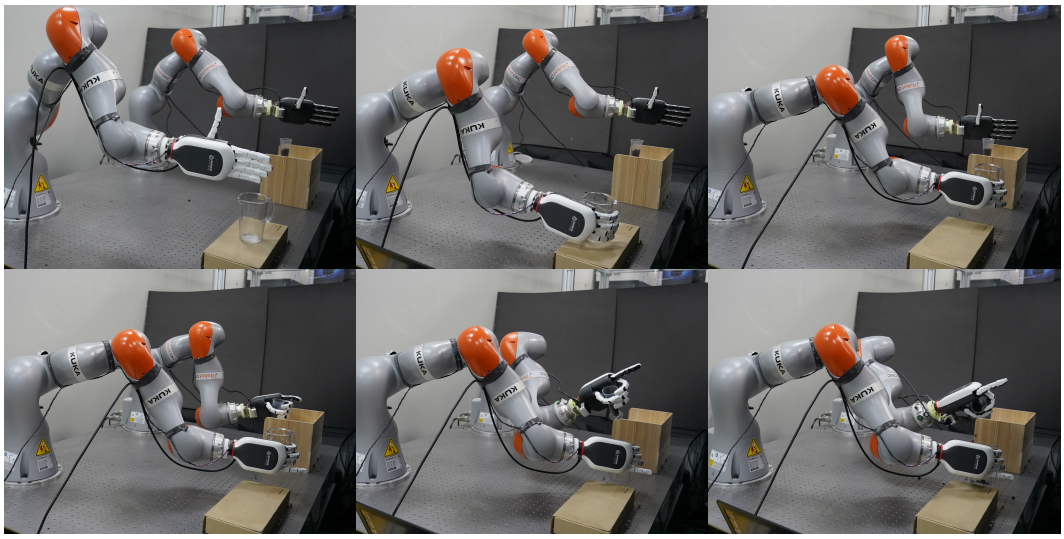


图 6: **Pouring Coffee Beans 具体流程**。双手拿起量杯, 将左手量杯中的咖啡豆倒入右手量杯。

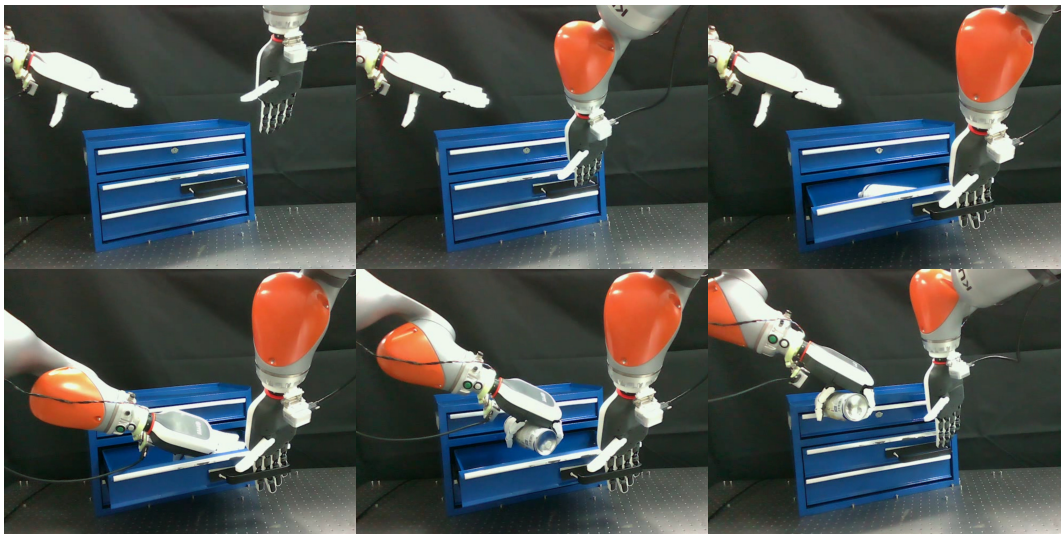


图 7: **Cabinet Retrieval 具体流程**。右手打开柜门、左手取出物体, 再由右手关闭柜门。

H 机器人仿真评测细节(Evaluation Details on Robotics Simulation)

我们报告 DexJoCo 上全部 11 个任务的完整任务级成功率, 包括 6 个单臂任务和 5 个双手协同任务。所有结果均采用附录 F 中相同的评测协议。对于具有多个随机种子的实验, 报告三个随机种子的平均成功率及标准差;最后分别给出单臂任务、双手任务和全部任务的宏平均成功率。

表 9: DexJoCo 基准上的完整任务级结果。

任务	单任务训练			多任务联合训练	
	$\pi_{0.5}$	GR00T N1.5	ARPG	$\pi_{0.5}$	ARPG
单臂任务					
Hammer Nail	84.7 ± 5.0	67.3 ± 4.2	72.0 ± 9.2	74.7 ± 2.3	52.7 ± 5.0
Click Mouse	64.7 ± 8.1	85.3 ± 3.1	73.3 ± 8.1	48.0 ± 6.9	96.0 ± 3.3
Pick Bucket	84.0 ± 7.2	72.0 ± 6.0	80.0 ± 2.0	60.7 ± 2.3	78.0 ± 1.6
Pinch Tongs	24.0 ± 6.9	12.7 ± 2.3	72.7 ± 13.0	44.0 ± 15.9	50.0 ± 1.6
Fold Glasses	72.0 ± 3.5	27.3 ± 2.3	58.0 ± 2.0	28.0 ± 4.0	41.3 ± 4.1
Water Plant	88.7 ± 3.1	72.7 ± 1.2	95.3 ± 2.3	79.3 ± 9.5	94.7 ± 3.4
双手任务					
Unlock iPad	36.0 ± 14.4	12.7 ± 11.0	30.0 ± 3.5	0.0 ± 0.0	25.3 ± 6.6
Hanoi	23.3 ± 7.0	0.7 ± 1.2	47.3 ± 11.5	4.7 ± 3.1	30.7 ± 3.4
Assembly	2.7 ± 2.3	0.7 ± 1.2	8.7 ± 2.3	4.0 ± 5.3	7.3 ± 0.9
Microwave	60.0 ± 5.3	50.7 ± 4.6	70.7 ± 6.1	34.7 ± 13.6	84.7 ± 5.3
Photograph	54.7 ± 8.1	40.7 ± 7.0	66.0 ± 7.2	7.3 ± 5.0	75.3 ± 6.2
单臂平均	**69.7**	**56.2**	**75.2 ± 2.5**	**55.8**	**68.8**
双手平均	**35.3**	**21.1**	**44.5 ± 4.1**	**10.1**	**44.7**
总体平均	**54.1 ± 1.8**	**40.2 ± 0.3**	**61.3 ± 2.8**	**35.0 ± 2.8**	**57.8 ± 0.4**

注:数值为成功率(%);若有报告,± 表示三个随机种子结果的标准差。